

Perbandingan Performa Convolutional Neural Network (CNN) From Scratch dan Transfer Learning (MobileNetV2) untuk Klasifikasi Citra

Aripin Suprianto

Jurusan Teknik Informatika

Universitas Darussalam Gontor

Email: aripinsuprianto52@student.cs.unida.gontor.ac.id

ABSTRACT

Eksperimen ini bertujuan untuk membandingkan secara komprehensif dua pendekatan utama dalam klasifikasi citra menggunakan deep learning: membangun arsitektur Convolutional Neural Network (CNN) dari awal (from scratch) dan memanfaatkan model yang telah dilatih sebelumnya (Transfer Learning) dengan arsitektur MobileNetV2. CNN dari awal diuji menggunakan dataset CIFAR-10 yang berukuran kecil (32×32 piksel), sedangkan Transfer Learning diterapkan pada dataset Cats vs Dogs dengan ukuran gambar yang lebih besar (150×150 piksel). Hasil pengujian menunjukkan bahwa pendekatan Transfer Learning memberikan keunggulan mutlak dalam akurasi pengujian (93,5%) dibandingkan dengan model CNN dari awal (68,2%) dengan waktu pelatihan yang jauh lebih efisien. Analisis dalam laporan ini membahas trade-off kedua metode berdasarkan ukuran dataset, ketersediaan komputasi, risiko overfitting, serta menyajikan penyelesaian untuk empat skenario studi kasus dunia nyata.

1. PENDAHULUAN

Klasifikasi citra merupakan salah satu domain utama dalam Visi Komputer yang mengalami perkembangan pesat semenjak adopsi arsitektur deep learning. Dalam praktiknya, pengembang dihadapkan pada dua pilihan utama: mendesain dan melatih jaringan saraf konvolusional (CNN) dari nol atau menggunakan paradigma *Transfer Learning*. Melatih CNN dari awal memberikan fleksibilitas penuh terhadap arsitektur jaringan, namun membutuhkan dataset berskala besar serta biaya komputasi yang tinggi agar model dapat menggeneralisasi fitur secara optimal. Di sisi lain, *Transfer Learning* memanfaatkan representasi fitur yang kaya dari model yang telah dilatih pada dataset raksasa seperti ImageNet, sehingga mampu mencapai akurasi tinggi meskipun dengan jumlah data yang terbatas dan waktu komputasi yang relatif singkat. Eksperimen ini menginvestigasi performa kedua pendekatan secara empiris dan menyusun argumentasi sistematis mengenai efisiensi masing-masing metode dalam skenario terapan.

2. DESKRIPSI DATASET

Dua dataset berbeda digunakan dalam eksperimen ini untuk merepresentasikan tantangan klasifikasi yang bervariasi:

1. **Dataset CIFAR-10 (CNN from Scratch):** Terdiri dari 60.000 gambar berwarna dengan ukuran piksel yang sangat rendah, yaitu 32×32 piksel. Dataset ini terbagi menjadi 10 kelas objek (pesawat, mobil, burung, kucing, rusa, anjing, katak, kuda, kapal, dan truk). Untuk kebutuhan eksperimen klasifikasi dasar, model dilatih mendeteksi seluruh kelas guna melihat kemampuan ekstraksi fitur mandiri pada pola citra beresolusi rendah.
2. **Dataset Cats vs Dogs (Transfer Learning):** Berisi gambar hewan berupa kucing dan anjing dengan resolusi yang bervariasi dan latar belakang (background) yang kompleks. Eksperimen dibatasi dengan mengambil sampel terkurasi sebanyak 2.500 gambar untuk menjaga kestabilan komputasi lokal, yang kemudian didistribusikan secara adil untuk memastikan keseimbangan data antarkelas.

3. PREPROCESSING DATA

Preprocessing data memegang peranan krusial untuk memastikan kestabilan matematis saat optimasi gradien. Langkah-langkah preprocessing yang diterapkan meliputi:

3.1. Normalisasi Nilai Piksel

Nilai intensitas warna pada gambar asli berkisar antara 0 hingga 255. Nilai ini dinormalisasi ke dalam rentang $[0.0, 1.0]$ dengan membagi setiap nilai piksel dengan 255.0. Hal ini mencegah terjadinya *exploding gradients* selama proses *back-propagation*.

3.2. Resizing (Pengubahan Ukuran Citra)

Untuk dataset Cats vs Dogs yang memiliki resolusi tidak seragam, seluruh gambar diubah ukurannya (*resized*) menjadi resolusi seragam 150×150 piksel agar sesuai dengan dimensi input lapisan pertama MobileNetV2.

3.3. Pembagian Dataset (Data Splitting)

Sesuai dengan ketentuan instruksi tugas, dataset dibagi menjadi tiga bagian utama dengan proporsi sebagai berikut:

- **Data Training (70%):** Digunakan untuk melatih dan memperbarui bobot (weights) model.
- **Data Validation (15%):** Digunakan untuk mengevaluasi model di setiap akhir epoch guna mendeteksi gejala overfitting.
- **Data Testing (15%):** Digunakan untuk pengujian akhir performa generalisasi model pada data yang belum pernah dilihat sebelumnya.

4. IMPLEMENTASI CNN FROM SCRATCH

Model CNN dari dasar dirancang secara sekuensial dengan mengombinasikan lapisan konvolusi, aktivasi, pooling, dan fully connected. Matematika dasar dari operasi konvolusi dua dimensi dinyatakan dalam persamaan berikut:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i-m, j-n) K(m, n) \quad (1)$$

Dimana I adalah citra input dan K adalah kernel/filter konvolusi. Arsitektur model yang diimplementasikan adalah sebagai berikut:

1. **Convolutional Layer 1:** 32 filter dengan ukuran kernel 3×3 , fungsi aktivasi *Rectified Linear Unit* (ReLU). Lapisan ini mengekstraksi fitur primitif seperti tepi dan sudut.
2. **Max Pooling Layer 1:** Ukuran pool 2×2 , mereduksi dimensi spasial citra hingga 50% untuk menghemat komputasi dan memberikan sifat *translation invariance*.
3. **Convolutional Layer 2 & 3:** Masing-masing menggunakan 64 filter ukuran 3×3 berbasis ReLU untuk mengekstraksi kombinasi fitur yang lebih kompleks.
4. **Flatten Layer:** Mengubah matriks fitur tiga dimensi menjadi vektor satu dimensi.
5. **Dense Layer (Hidden Layer):** Memiliki 64 neuron dengan aktivasi ReLU untuk mempelajari kombinasi non-linear dari fitur yang diekstrak.
6. **Output Layer:** Memiliki 10 neuron dengan fungsi aktivasi *Softmax* untuk menghasilkan probabilitas multi-kelas pada dataset CIFAR-10. Optimizer yang digunakan adalah Adam dengan fungsi kerugian *Sparse Categorical Cross-Entropy*.

5. IMPLEMENTASI TRANSFER LEARNING

Pendekatan kedua menerapkan metode *Feature Extraction* menggunakan arsitektur **MobileNetV2** yang telah dilatih pada dataset ImageNet. Langkah implementation mencakup:

1. **Freezing Base Model:** Seluruh lapisan bawaan dari MobileNetV2 dibekukan (*trainable = False*). Hal ini krusial agar bobot ekstraktor fitur yang sudah matang tidak rusak oleh gradien acak pada awal latihan.
2. **Global Average Pooling 2D (GAP):** Menggantikan lapisan Flatten konvensional guna mereduksi representasi spasial dengan mengambil nilai rata-rata dari tiap *feature map*, secara signifikan mengurangi jumlah parameter dan menekan risiko overfitting.
3. **Classifier Output Layer:** Lapisan Dense dengan 1 neuron tunggal menggunakan fungsi aktivasi *Sigmoid* karena dataset Cats vs Dogs merupakan klasifikasi biner. Model dioptimasi menggunakan Adam dengan fungsi kerugian *Binary Cross-Entropy*:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (2)$$

6. HASIL EKSPERIMEN DAN PERBANDINGAN MODEL

Eksperimen dijalankan pada GPU kluster lokal. Data metrik hasil pelatihan dikumpulkan secara objektif dan dirangkum dalam tabel berikut:

Table 1: Tabel Perbandingan Parameter dan Performa Model

Aspek Perbandingan	CNN from Scratch	Transfer Learning
Akurasi Training	76,4%	96,8%
Akurasi Validation	69,1%	94,2%
Akurasi Testing	68,2%	93,5%
Loss Training	0,6642	0,0812
Loss Validation	0,9104	0,1435
Waktu Training	182 detik	45 detik
Jumlah Parameter	122.570	2.259.265
Risiko Overfitting	Tinggi	Rendah
Kemudahan Impl.	Sedang	Sangat Mudah
Kesesuaian Dataset	Kurang Optimal	Sangat Sesuai

Berdasarkan data di atas, model CNN dari awal menunjukkan performa yang cukup baik untuk arsitektur sederhana pada data CIFAR-10, namun terdapat gap sebesar $\sim 7\%$ antara akurasi training dan pengujian yang mengindikasikan adanya tanda-tanda *overfitting* ringan. Sebaliknya, Transfer Learning mencapai akurasi testing sebesar 93,5% hanya dalam 5 epoch dengan stabilitas kurva loss yang sangat mulus dan konvergen lebih cepat.

7. ANALISIS DEEP LEARNING

7.1. Analisis Dataset

1. **Kecukupan Ukuran Dataset:** Dataset CIFAR-10 (50.000 data latih) secara kuantitas cukup untuk melatih CNN

sederhana, namun resolusi 32×32 piksel membatasi variasi detail tekstur objek. Untuk dataset Cats vs Dogs yang diekstrak sebanyak 2.500 gambar, jumlah ini tergolong sangat kurang jika harus melatih CNN dari nol, namun sangat ideal dan mencukupi ketika dipadukan dengan Transfer Learning.

2. **Variasi Gambar dan Noise:** Dataset Cats vs Dogs memiliki variasi pencahayaan yang tinggi, pose hewan yang beragam, serta background yang kompleks (noise tinggi). Kualitas dataset seperti ini melemahkan CNN dari nol karena model kesulitan menyaring noise tanpa data yang masif. Sebaliknya, MobileNetV2 mampu menangani background kompleks tersebut karena telah mempelajari filter generalis pada ImageNet.

7.2. Analisis Performa Model

Model Transfer Learning memberikan hasil terbaik karena arsitektur dasarnya mendalam (deep network) namun efisien, serta memanfaatkan ekstraksi fitur tingkat tinggi (*high-level features*) yang tidak mampu dibentuk oleh model CNN dari nol dalam waktu singkat. Akurasi tinggi tidak selalu berarti model lebih baik jika terjadi *data leakage* atau ketidakseimbangan kelas, namun karena data dalam eksperimen ini seimbang dan dievaluasi dengan *confusion matrix*, capaian akurasi tinggi tersebut valid merepresentasikan keunggulan model.

7.3. Analisis Pemilihan Pendekatan

Berdasarkan hasil eksperimen, kesimpulan kapan harus memilih masing-masing metode dirumuskan sebagai berikut:

- **Gunakan CNN from Scratch jika:** Ukuran dataset sangat besar (ratusan ribu hingga jutaan gambar), domain data sangat spesifik/terisolasi (misal citra satelit atau mikroskopis yang tidak memiliki kesamaan fitur dengan ImageNet), tersedia infrastruktur komputasi tinggi (multi-GPU), dan tidak ada batasan waktu pengerjaan yang ketat.
- **Gunakan Transfer Learning jika:** Dataset berukuran kecil atau menengah, dikejar oleh tenggat waktu *deployment* yang cepat, keterbatasan memori atau GPU, serta karakteristik objek menyerupai objek natural yang ada pada ImageNet.

8. STUDI KASUS PENGAMBILAN KEPUTUSAN

- **Skenario 1 (Klinik Medis, 300 Gambar):** Dipilih pendekatan **Transfer Learning**. Alasan utamanya adalah jumlah data yang sangat ekstrem kecil (300 gambar). Melatih CNN dari awal dipastikan akan mengalami *overfitting total* dan model hanya akan menghafal data latih. Meskipun gambar medis berbeda dari ImageNet, fitur-fitur primitif seperti bentuk lingkaran, tepi, dan kontras tekstur dari pretrained model jauh lebih berharga daripada melatih bobot acak.
- **Skenario 2 (Perusahaan, 1 Juta Gambar Produk Unik):** Dipilih pendekatan **CNN from Scratch** (atau fine-tuning

penuh pada seluruh layer jaringan). Alasan: Dataset berukuran masif (1 juta) membuang risiko overfitting dan memberikan data yang cukup bagi model untuk belajar dari nol. Karakteristik yang sangat berbeda dari ImageNet mengindikasikan bahwa fitur visual ImageNet tidak akan relevan, sehingga membuat model spesifik dari nol adalah keputusan terbaik.

- **Skenario 3 (Prototipe 2 Hari, 500 Gambar):** Dipilih pendekatan **Transfer Learning (Feature Extraction)**. Alasan rasionalitas: Batasan waktu dua hari tidak memberikan ruang untuk eksperimen arsitektur hyperparameter CNN dari nol. *Feature extraction* membekukan layer bawah dan hanya melatih pengklasifikasi akhir, yang dapat diselesaikan dan memberikan akurasi di atas 90% dalam hitungan menit pelatihan.
- **Skenario 4 (Dataset Besar, GPU Mewah, Domain Spesifik):** Apakah Transfer Learning tetap diperlukan? **Tidak wajib, tetapi direkomendasikan sebagai inisialisasi bobot.** Alasan: Dengan GPU memadai dan data besar, melatih CNN dari awal sangat memungkinkan. Namun, menggunakan arsitektur pretrained seperti ResNet50 sebagai *backbone* awal (*weight initialization*) terbukti mempercepat proses *convergence* (waktu konvergensi loss) dibandingkan memulai dari bobot acak biasa (*random weights*).

9. KESIMPULAN DAN REFLEKSI PRIBADI

1. **Tantangan Terbesar:** Mengelola penyesuaian bentuk (*shape alignment*) matriks input antar dataset yang berbeda dan mengonfigurasi pipeline data lokal agar memori GPU tidak mengalami *Out of Memory* (OOM) saat memuat model MobileNetV2.
2. **Bagian Paling Sulit:** Membangun CNN dari awal. Proses penentuan jumlah lapisan konvolusi, ukuran filter, penempatan lapisan pooling, serta penalaan *learning rate* menuntut banyak *trial and error* karena model sangat sensitif terhadap perubahan parameter kecil.
3. **Perbedaan Paling Terasa:** Efisiensi waktu pelatihan dan stabilitas nilai loss. Menggunakan model pretrained terasa sangat instan; nilai loss langsung mengecil secara drastis sejak epoch pertama, berbeda dengan melatih dari nol yang membutuhkan beberapa epoch awal hanya untuk memahami struktur objek gambar.
4. **Pilihan Kasus Nyata:** Saya akan mengutamakan pendekatan **Transfer Learning**. Dalam industri nyata, efisiensi waktu, akurasi tinggi di awal, dan minimalisasi biaya sewa komputasi awan (cloud computing) adalah prioritas bisnis utama.
5. **Hal Baru yang Dipelajari:** Pengambilan keputusan dalam deep learning tidak hanya berfokus pada hasil akurasi akhir, melainkan sebuah seni menyeimbangkan batasan dunia nyata (*real-world constraints*) seperti ketersediaan data, anggaran GPU, tenggat waktu proyek, dan ukuran model untuk kemudahan *deployment*.